

# Assignment 4 2024 msb105

## Innholdsfortegnelse

|   |    |
|---|----|
| restatapi . . . . .                                       | 3  |
| Toc. eurostat . . . . .                                   | 4  |
| GDP NUTS 3 . . . . .                                      | 4  |
| Population demo_r_pjanaggr3 . . . . .                     | 7  |
| Oppgave . . . . .   | 7  |
| Oppgave . . . . .   | 9  |
| Alternative populasjonsdata . . . . .                     | 9  |
| Bearbeiding av populasjonsdata . . . . .                  | 9  |
| Oppgave . . . . .   | 9  |
| Oppgave . . . . .   | 10 |
| Oppgave . . . . .   | 10 |
| Oppgave . . . . .   | 10 |
| Oppgave . . . . .   | 10 |
| Oppgave . . . . .   | 10 |
| Oppgave . . . . .   | 11 |
| Oppgave . . . . .   | 12 |
| Oppgave . . . . .   | 12 |
| Oppgave . . . . .   | 14 |
| Oppgave . . . . .   | 14 |
| Oppgave . . . . .   | 14 |
| Beregning av Gini på NUTS2, NUTS1 og NUTSc nivå . . . . . | 15 |
| Gini-koeffisient for NUTS2 . . . . .                      | 15 |
| Oppgave . . . . .   | 15 |
| Oppgave . . . . .   | 17 |
| Oppgave . . . . .   | 18 |
| «Nestete» datastrukturer . . . . .                        | 19 |
| Oppgave . . . . .   | 19 |
| Oppgave . . . . .   | 19 |
| Oppgave . . . . .   | 19 |
| Oppgave . . . . .   | 19 |
| Resultatet . . . . .                                      | 20 |

|   |    |
|---|----|
| Plots som viser utviklingen . . . . .                                       | 22 |
| Oppgave . . . . .   | 22 |
| Oppgave . . . . .   | 24 |
| Hvordan er verdiskapningen fordelt mellom regionene i ulike land? . . . . . | 25 |
| Spania . . . . .  | 25 |
| Oppgave . . . . .   | 25 |
| Oppgave . . . . .   | 25 |
| Oppgave . . . . .   | 25 |
| Oppgave . . . . .   | 25 |
| Tyskland . . . . .  | 25 |
| Oppgave . . . . .   | 26 |
| Oppgave . . . . .   | 26 |
| Frankrike . . . . .   | 26 |
| Oppgave . . . . .   | 27 |
| Oppgave . . . . .   | 28 |
| Oppgave . . . . .   | 28 |
| Oppgave . . . . .   | 28 |
| Oppgave . . . . .   | 28 |
| Enkle modeller . . . . .  | 28 |
| «Data Science» modeller . . . . .   | 29 |
| Oppgave . . . . .   | 29 |
| Oppgave . . . . .   | 29 |
| Panel modell . . . . .  | 31 |

Denne oppgaven vil handle om å hente ned regionale data fra EU sin statistikk organisasjon [eurostat](<https://ec.europa.eu/eurostat>). Vi vil hente data direkte inn i R vha. en api. Dataene vil vi aggregere på ulike nivå fra NUTS3 (laveste nivå) opp via NUTS2 og NUTS1 til nasjons-nivå. Vi vil benytte Rs støtte via `tidyverse` for såkalte list-columns. Dette muliggjør «nested» data som vil si at vi kan ha en liste av tibbles som variabel i en tibble. Målet vårt er å ordne dataene som vist i Figur 1. Kolonnene `NUTS3_data` til `NUTSc_data` vil innholde data om brutto-nasjonalprodukt, befolkning, BNP per person og beregnet Gini-koeffisient for likhet/ulikhet mellom regioner mht. verdiskaping. Vi vil altså ha disse dataene på fire ulike aggregeringsnivå. Dataene vil dekke perioden 2000-2021.

mht.

Når dataene er hentet og organisert vil vi produsere ulike plots og også estimere noen enkle modeller.

Løsning av oppgaven vil benytte teknikker dekket i [Many models slides](#) og [r4ds ed. 1 chp. 25] (<https://r4ds.had.co.nz/many-models.html>). Videre vil vi benytte avbilding (mapping) av anonyme funksjoner på list-columns. Dette er dekket i [r4ds ed. 1 chp. 21](#) og [r4ds ed. 1 chp. 19](#). Pakkene jeg benyttet er listet i setup chunk-en.

Vi vil se at det har vært endring i sonene i Belgia, Italia og Norge. Vi vil derfor ha soner som eksisterer i befolkningstabellene, men ikke i bnp tabellene. Vi kunne selv ha gjort en aggregering av dataene for å få samsvarende data. Vi dropper imidlertid dette i denne øvelsen. Det er nok å holde styr på allerede.

|    | country_name | country | NUTS3_data             | NUTS2_data            | NUTS1_data            | NUTSc_data           |
|----|--------------|---------|------------------------|-----------------------|-----------------------|----------------------|
| 1  | Østerrike    | AT      | <data.frame[770 x 8]>  | <data.frame[198 x 7]> | <data.frame[66 x 7]>  | <data.frame[22 x 7]> |
| 2  | Belgia       | BE      | <data.frame[836 x 8]>  | <data.frame[209 x 7]> | <data.frame[57 x 7]>  | <data.frame[19 x 7]> |
| 3  | Sveits       | CH      | <data.frame[364 x 8]>  | <data.frame[98 x 7]>  | <data.frame[14 x 7]>  | <data.frame[14 x 7]> |
| 4  | Tyskland     | DE      | <data.frame[8822 x 8]> | <data.frame[836 x 7]> | <data.frame[352 x 7]> | <data.frame[22 x 7]> |
| 5  | Danmark      | DK      | <data.frame[264 x 8]>  | <data.frame[132 x 7]> | <data.frame[44 x 7]>  | <data.frame[22 x 7]> |
| 6  | Hellas       | EL      | <data.frame[1144 x 8]> | <data.frame[286 x 7]> | <data.frame[88 x 7]>  | <data.frame[22 x 7]> |
| 7  | Spania       | ES      | <data.frame[1320 x 8]> | <data.frame[440 x 7]> | <data.frame[176 x 7]> | <data.frame[22 x 7]> |
| 8  | Finland      | FI      | <data.frame[418 x 8]>  | <data.frame[110 x 7]> | <data.frame[44 x 7]>  | <data.frame[22 x 7]> |
| 9  | Frankrike    | FR      | <data.frame[2222 x 8]> | <data.frame[594 x 7]> | <data.frame[308 x 7]> | <data.frame[22 x 7]> |
| 10 | Irland       | IE      | <data.frame[169 x 8]>  | <data.frame[66 x 7]>  | <data.frame[22 x 7]>  | <data.frame[22 x 7]> |
| 11 | Italia       | IT      | <data.frame[2376 x 8]> | <data.frame[484 x 7]> | <data.frame[132 x 7]> | <data.frame[22 x 7]> |
| 12 | Nederland    | NL      | <data.frame[902 x 8]>  | <data.frame[286 x 7]> | <data.frame[110 x 7]> | <data.frame[22 x 7]> |
| 13 | Norge        | NO      | <data.frame[182 x 8]>  | <data.frame[112 x 7]> | <data.frame[28 x 7]>  | <data.frame[14 x 7]> |
| 14 | Polen        | PL      | <data.frame[1606 x 8]> | <data.frame[374 x 7]> | <data.frame[154 x 7]> | <data.frame[22 x 7]> |
| 15 | Portugal     | PT      | <data.frame[550 x 8]>  | <data.frame[154 x 7]> | <data.frame[66 x 7]>  | <data.frame[22 x 7]> |
| 16 | Sverige      | SE      | <data.frame[462 x 8]>  | <data.frame[176 x 7]> | <data.frame[66 x 7]>  | <data.frame[22 x 7]> |

Figur 1: Regionale data for et utvalg EU/EØS nasjoner.

## HAPPY CODING 8-)

```

```{r}
#| label: setup
#| message: false
library(tidyverse)
library(readxl)
library(restatapi)
library(DescTools)
library(ggrepel)
library(flextable)
library(modelr)
library(plm)
library(broom)
library(sandwich)
```

```

## restatapi

Vi benytter pakken `restatapi` for å kommunisere med Eurostat. Vi vil benytte

- `get_eurostat_toc()` for å hente innholdsfortegnelse og kode-navn for tabellene vi ønsker,
- `get_eurostat_dsd()` for å se hvilke variabler som finnes i tabellen og hvordan de er kodet og

- `get_eurostat_data()` for å hente selve dataene.

Nedenfor vil jeg vise hvordan vi henter regionale GDP data for et utvalg land. Vi vil hente data på NUTS3 nivå (5 karakter kode) og aggregere opp til NUTS2 (4 karakter kode), NUTS1 (3 karakter kode) og NUTSc (nasjons) nivå (2 karakter kode). Dere vil hente to ulike datasett om befolkning på tilsvarende vis.

## Toc. eurostat

Vi starter med å hente innholdsfortegnelsen fra eurostat. Vi henter innholdsfortegnelsen i rent tekst format. Innholdsfortegnelsen gir vi navnet `toc_txt`.

```
# xml skal ha mer detaljert info
# toc_xml <- get_eurostat_toc()
# tekstversjonen har trolig nok info for vårt formål
toc_txt <- get_eurostat_toc(mode = "txt")
```

## GDP NUTS 3

Vi søker i `toc_txt` etter tabeller med GDP på nivå NUTS 3 vha. funksjonen `str_detect()`. Denne funksjonen skiller mellom store og små bokstaver. Siden vi ikke vet hvilken skrivemåte som er brukt for gdp og NUTS 3 benytter vi regex for å matche både små og store bokstaver. Vi benytter `filter()` for å finne de tabellene vi ønsker. Vi benytter `select()` for å velge ut kolonnene `title` og `code` som vi ønsker å se på. Vi benytter `flectable()` for å vise tabellen. Vi benytter til slutt `autofit()` for å tilpasse tabellen til siden. Detaljer om regex finner dere i [Slides: Strings and regular expressions](#) og i [r4ds ed. 1 chp. 14](#).

Vi ønsker å finne tabellbeskrivelser som *både* inneholder gdp *og* nuts 3. Trikset for enkelt å få dette til er å ha AND (&) *utenfor* `str_detect()`. Det går an å få til en AND inne i en regexp, men dette kan fort bli kronglete og komplisert.

```
gdp_tabs <- toc_txt |>
# Regex AND external to regex
  filter(
    str_detect(
      string = title,
      # For å matche både små og store bokstaver
      pattern = '[Gg][Dd][Pp]'
      # AND vha. &
    ) &
    str_detect(
      string = title,
      # For å matche både små og store bokstaver og
      # space eller ikke før 3
      pattern = '[Nn][Uu][Tt][Ss]\\s*3'
```

```
)
) |>
select(title, code)
```

Vi finner fire tabeller listet i `toc_txt`.

```
gdp_tabs |>
  select(title, code) |>
  flextable() |>
  width(1, width = 3.5) |>
  width(2, width = 1.5)
```

Tabell 1: Tabeller med GDP på NUTS 3 nivå.

| title  | code             |
|--|------------------|
| Average annual population to calculate regional GDP data (thousand persons) by NUTS 3 region | nama_10r_3popgdp |
| Gross domestic product (GDP) at current market prices by NUTS 3 region                       | nama_10r_3gdp    |
| European Union trade mark (EUTM) applications per billion GDP by NUTS 3 region (2000-2014)   | ipr_ta_gdpr      |
| Community design (CD) applications per billion GDP by NUTS 3 region (2003-2014)              | ipr_da_gdpr      |

Vi velger å benytte tabellen med kode `nama_10r_3gdp` som har forklarende tekst «Gross domestic product (GDP) at current market prices by NUTS 3 regions». Vi henter «Data Structure Definition» for å finne hva som finnes i dette datasettet. Informasjonen benyttes for å definere «filters» for spørringen mot eurostat.

MERK! Merk bruken av `nuts_level = "3"` i filters for å få data på NUTS 3 nivå. Denne parameteren var ikke så lett å finne.

Vi laster så ned «Data Structure Definition (DSD)» for tabellen med code `nama_10r_3gdp`.

```
# description nama_10r_3gdp
dsd_gdp <- get_eurostat_dsd("nama_10r_3gdp")
```

```
dsd_gdp |>
  head(n = 15) |>
  flextable() |>
  width(j = 1, width = 1) |>
  width(j = 2, width = 2) |>
  width(j = 3, width = 2)
```

| concept | code              | name  |
|---------|-------------------|---|
| freq    | A                 | Annual  |
| unit    | MIO_EUR           | Million euro  |
| unit    | EUR_HAB           | Euro per inhabitant   |
| unit    | EUR_HAB_EU27_2020 | Euro per inhabitant in percentage of the EU27 (from 2020) average   |
| unit    | MIO_NAC           | Million units of national currency  |
| unit    | MIO_PPS_EU27_2020 | Million purchasing power standards (PPS, EU27 from 2020)  |
| unit    | PPS_EU27_2020_HAB | Purchasing power standard (PPS, EU27 from 2020), per inhabitant   |
| unit    | PPS_HAB_EU27_2020 | Purchasing power standard (PPS, EU27 from 2020), per inhabitant in percentage of the EU27 (from 2020) average |
| geo     | EU27_2020         | European Union - 27 countries (from 2020)   |
| geo     | BE                | Belgium   |
| geo     | BE1               | Région de Bruxelles-Capitale/Brussels Hoofdstedelijk Gewest   |
| geo     | BE10              | Région de Bruxelles-Capitale/Brussels Hoofdstedelijk Gewest   |
| geo     | BE100             | Arr. de Bruxelles-Capitale/Arr. Brussel-Hoofdstad   |
| geo     | BE2               | Vlaams Gewest   |
| geo     | BE21              | Prov. Antwerpen   |

Utfra kodene i `dsd_gdpkan` vi da formulere følgende spørring mot Eurostat:

```
# Gross domestic product (GDP) at current market prices by NUTS 3 regions
# id: nama_10r_3gdp
nama_10r_3gdp <- get_eurostat_data(
  id = "nama_10r_3gdp",
  filters = list(
    geo = c("AT", "DE", "DK", "FR", "EL", "ES",
            "IT", "NL", "BE", "IE", "PL", "PT", "NO", "SE", "FI", "CH"),
    nuts_level = "3",
    unit = "MIO_PPS_EU27_2020"
  ),
  exact_match = FALSE,
  date_filter = 2000:2021,
  stringsAsFactors = FALSE
) |>
mutate(
  gdp = 1000000 * values
) |>
select(-c(unit, values)) |>
# Vil bare ha NUTS 3 nivå (5 karakterer). Vil aggregere selv til NUTS2,
# NUTS1 og NUTSc
filter(str_length(geo) == 5)
```

Vi velger å benytte MIO\_PPS\_EU27\_2021 som mål på GNP. Dette er GNP i løpende priser (million Euro). Det kunne vært aktuelt å benytte PPS\_EU27\_2021\_HAB som skal være GNP målt i konstant kjøpekraft. Det synes imidlertid som om PPS\_EU27\_2021\_HAB har urimelige/åpenbart feil verdier for en del regioner.

## Population demo\_r\_pjanaggr3

### Oppgave

1. Søk i `toc_txt` for tabeller med *population* og *NUTS 3*. Pass på at dere dekker både *population* og *Population* og ulike skrivemåter for *NUTS 3*.

| title   | code             |
|---|------------------|
| Population density by NUTS 3 region                               | demo_r_d3dens    |
| Population on 1 January by age group, sex and NUTS 3 region       | demo_r_pjangrp3  |
| Population on 1 January by broad age group, sex and NUTS 3 region | demo_r_pjanaggr3 |
| Population structure indicators by NUTS 3 region                  | demo_r_pjanind3  |

| title  | code             |
|--|------------------|
| Population change - Demographic balance and crude rates at regional level (NUTS 3)                                   | demo_r_gind3     |
| Population by single year of age and NUTS 3 region   | cens_11ag_r3     |
| Population by marital status and NUTS 3 region   | cens_11ms_r3     |
| Population by family status and NUTS 3 region  | cens_11fs_r3     |
| Population by sex, citizenship and NUTS 3 region   | cens_01rsctz     |
| Population by sex, age group, current activity status and NUTS 3 region  | cens_01rapop     |
| Total and active population by sex, age, employment status, residence one year prior to the census and NUTS 3 region | cens_01ramigr    |
| Population by sex, age group, educational attainment level, current activity status and NUTS 3 region                | cens_01rews      |
| Population by sex, age group, household status and NUTS 3 region   | cens_01rhtype    |
| Population by sex, age group, size of household and NUTS 3 region  | cens_01rhsiz     |
| Average annual population to calculate regional GDP data (thousand persons) by NUTS 3 region                         | nama_10r_3popgdp |
| European Union trade mark (EUTM) applications per million population by NUTS 3 region (1996-2015)                    | ipr_ta_popr      |
| Community design (CD) applications per million population by NUTS 3 region (2003-2015)                               | ipr_da_popr      |
| Population with Ukrainian citizenship by 5-year age group and NUTS 3 region  | cens_21ua_a5r3   |
| Population with Ukrainian citizenship by age and NUTS 3 region   | cens_21ua_ar3    |
| Population with Ukrainian citizenship by 5-year age group, marital status and NUTS 3 region                          | cens_21ua_msr3   |
| Population by broad age group and NUTS 3 region  | cens_21agr3      |
| Population on 1st January by age, sex, type of projection and NUTS 3 region  | proj_19rp3       |



Vi vil i hovedsak bruke befolkningstabellen som har teksten: «Average annual population to calculate regional GDP data (thousand persons) by NUTS 3 regions», men siden denne synes å ha manglende data for noen regioner vil vi supplere med data fra tabellen med teksten «Population on 1 January by broad age group, sex and NUTS 3 region».

## Oppgave

2.
  - i. Finn koden for tabellen med forklarende tekst «Average annual population to calculate regional GDP data (thousand persons) by NUTS 3 regions».
  - ii. Last ned Data Structure Definition (DSD) for denne tabellen.
  - iii. Bruk opplysningene i DSD for å formulere en spørring mot Eurostat og last ned dataene. Gi dataene lastet ned samme navn som Eurostat sin kode for tabellen. Vi er bare interessert i totalbefolkning og ignorerer derfor både kjønn og alder. Vi ønsker data for årene 2000-2021.
  - iv. Bruk `filter(str_length(geo) == 5)` for å begrense datasettet til NUTS3 regioner. Vi vil gjøre vår egen aggregering.
  - v. Hent data for landene:

```
c("AT", "DE", "DK", "FR", "EL", "ES", "IT", "NL", "BE",  
  "IE", "PL", "PT", "NO", "SE", "FI", "CH")
```

## Alternative populasjonsdata

3. Hent ned befolningsdata fra tabellen som har teksten «Population on 1 January by broad age group, sex and NUTS 3 region». Gi også her dataene samme navn som tabell-koden hos Eurostat. Igjen vil vi ikke skille på kjønn eller alder.

## Bearbeiding av populasjonsdata

Vi vil ta utgangspunkt i populasjonsdata fra tabellen «Average annual population to calculate regional GDP data (thousand persons) by NUTS 3 regions» og supplere med data fra tabellen «Population on 1 January by broad age group, sex and NUTS 3 region» der data mangler.

## Oppgave

4. Bruk `setdiff()` for å finne NUTS3 soner som inngår i «Average annual population to calculate regional GDP data (thousand persons) by NUTS 3 regions», men ikke i «Population on 1 January by broad age group, sex and NUTS 3 region».

```
[1] "DKZZZ" "ESZZZ" "ITZZZ" "NLZZZ" "NOZZZ"
```

### Oppgave

5. Bruk `setdiff()` for å finne NUTS3 soner som inngår i «Population on 1 January by broad age group, sex and NUTS 3 region», men ikke i «Average annual population to calculate regional GDP data (thousand persons) by NUTS 3 regions».

```
[1] "BE221" "BE222" "BE321" "BE322" "BE324" "BE325" "BE326" "BE327" "FRXXX"
[10] "ITG25" "ITG26" "ITG27" "ITG28" "ITG29" "ITG2A" "ITG2B" "ITG2C" "N0011"
[19] "N0012" "N0021" "N0022" "N0031" "N0032" "N0033" "N0034" "N0041" "N0042"
[28] "N0043" "N0051" "N0052" "N0053" "N0061" "N0062" "N0072" "N0073" "N00B1"
```

### Oppgave

6. Gjør en `full_join()` av de to populasjonstabellene. Gi resultatet navnet `full_pop_nuts3`.

### Oppgave

7. Bruk `setdiff()` for å sjekke sonene i `full_pop_nuts3` mot dem vi har i GDP tabellen.

```
[1] "BE221" "BE222" "BE321" "BE322" "BE324" "BE325" "BE326" "BE327" "FRXXX"
[10] "ITG25" "ITG26" "ITG27" "ITG28" "ITG29" "ITG2A" "ITG2B" "ITG2C" "N0011"
[19] "N0012" "N0021" "N0022" "N0031" "N0032" "N0033" "N0034" "N0041" "N0042"
[28] "N0043" "N0051" "N0052" "N0053" "N0061" "N0062" "N0072" "N0073" "N00B1"
```

### Oppgave

8. Bruk `setdiff()` for å sjekke sonene i GDP tabellen mot dem vi har i `full_pop_nuts3`.

```
[1] "ATZZZ" "BEZZZ" "FIZZZ" "FRZZZ" "PTZZZ" "SEZZZ"
```

**\*\*ZZZ** ser ut til å være en slags oppsamlingskategori i gdp-dataene. Vi har ikke tilsvarende for befolkning så disse har vi ingen bruk for.

### Oppgave

9. Fjern **\*\*ZZZ** sonene fra `nama_10r_3gdp`.

Følgende illustrerer problemet i `full_pop_nuts3`.

```
full_pop_nuts3 |>
  filter(geo %in% c("N0053", "N0060", "N0061")) |>
  filter(time %in% 2014:2021) |>
  arrange(time, geo)
```

|     | geo    | time   | pop.x  | pop.y  |
|-----|--------|--------|--------|--------|
|     | <char> | <char> | <num>  | <num>  |
| 1:  | N0053  | 2014   | 261458 | NA     |
| 2:  | N0060  | 2014   | 444966 | 443090 |
| 3:  | N0061  | 2014   | 306067 | NA     |
| 4:  | N0053  | 2015   | 263736 | NA     |
| 5:  | N0060  | 2015   | 449386 | 447910 |
| 6:  | N0061  | 2015   | 310093 | NA     |
| 7:  | N0053  | 2016   | 265151 | NA     |
| 8:  | N0060  | 2016   | 453352 | 452090 |
| 9:  | N0061  | 2016   | 313105 | NA     |
| 10: | N0053  | 2017   | 266274 | NA     |
| 11: | N0060  | 2017   | 458221 | 457000 |
| 12: | N0061  | 2017   | 317363 | NA     |
| 13: | N0053  | 2018   | 266858 | NA     |
| 14: | N0060  | 2018   | 462354 | 460170 |
| 15: | N0061  | 2018   | 320884 | NA     |
| 16: | N0053  | 2019   | 267420 | NA     |
| 17: | N0060  | 2019   | 465634 | 465910 |
| 18: | N0053  | 2020   | 267642 | NA     |
| 19: | N0060  | 2020   | 468702 | 469910 |
| 20: | N0060  | 2021   | 471124 | 473000 |

Vi ønsker å benytte dataene fra «Average annual population to calculate regional GDP data (thousand persons) by NUTS 3 regions» (pop.x) der disse eksisterer og supplere med data fra «Population on 1 January by broad age group, sex and NUTS 3 region» (pop.y) der vi mangler data. Mangler vi data i begge tabellene setter vi verdien lik NA. (Hint! Sjekk `ifelse()`)

## Oppgave

10. Lag en ny variabel `pop` i `full_pop_nuts3` ut fra diskusjonen ovenfor. Dropp deretter variablene `pop.x` og `pop.y`.

```
full_pop_nuts3 <- full_pop_nuts3 |>
  mutate(
    pop = ifelse(
```

```

    test = is.na(pop.x) == TRUE,
    yes = pop.y,
    no = pop.x
  )
) |>
select(-pop.x, -pop.y)

```

Har vi noen pop lik 0? Disse vil skape problemer når vi skal regne ut gdp\_per\_capita. En befolkning lik 0 betyr i denne sammenheng manglende data. Vi bør derfor rekode disse til NA hvis de finnes.

## Oppgave

- Undersøk om vi har noen NUTS 3 soner med pop lik 0. Hvis det er noen så rekode disse til NA.

Vi har ovenfor sett at vi har et helt sett av NUTS3 regioner som finnes i befolkningsdata, men ikke i gdp datasettet. Vi kan ikke bruke disse, men fjerner dem lett vha. en left\_join der x er gdp-data. Da legger vi bare til befolkningsdata for de sonene hvor vi har gdp-data.

## Oppgave

- Utfør en left\_join() der populasjonsdata blir lagt til datasettet som inneholder GDP-data. Gi resultatet navnet eu\_data.

```
dim(eu_data)
```

```
[1] 22407      4
```

Sjekker hvor mange NUTS3 soner vi har i hvert land. Lager først en ny variabel country fra de to første karakterene i NUTS3

```

eu_data <- eu_data |>
  mutate(
    country = str_sub(geo, start = 1L, end = 2L)
  )

```

Sjekker så antall NUTS3

```

eu_data |>
  distinct(geo, .keep_all = TRUE) |>
  group_by(country) |>
  summarise(Antall = n(), .groups = "drop")

```

```
# A tibble: 16 x 2
  country Antall
  <chr>      <int>
1 AT         35
2 BE         44
3 CH         26
4 DE        401
5 DK         12
6 EL         52
7 ES         60
8 FI         19
9 FR        101
10 IE         8
11 IT        108
12 NL         41
13 NO         13
14 PL         73
15 PT         25
16 SE         21
```

Sjekker også summary for variablene i eu\_data

```
eu_data |>
  summary()
```

| geo              | time             | gdp               | pop             |
|------------------|------------------|-------------------|-----------------|
| Length:22407     | Length:22407     | Min. :8.553e+07   | Min. : 8400     |
| Class :character | Class :character | 1st Qu.:2.968e+09 | 1st Qu.: 132773 |
| Mode :character  | Mode :character  | Median :5.394e+09 | Median : 241155 |
|                  |                  | Mean :1.018e+10   | Mean : 372973   |
|                  |                  | 3rd Qu.:1.049e+10 | 3rd Qu.: 439273 |
|                  |                  | Max. :2.606e+11   | Max. :6726640   |
|                  |                  |                   | NA's :116       |
| country          |                  |                   |                 |
| Length:22407     |                  |                   |                 |
| Class :character |                  |                   |                 |
| Mode :character  |                  |                   |                 |

Endrer navn og rekkefølge på variabelen i eu\_data vha. select().

```
eu_data <- eu_data |>
  select(country, NUTS3 = geo, year = time, gdp, pop)
```

```
# Rydder opp
# Sletter alle objekt utenom eu_data
# don't use if you don't mean it
rm(list = setdiff(ls(), "eu_data"))
```

Nå skal vi ha orden i rådataene.

## Oppgave

13. Beregn `gdp_per_capita` for hver NUTS3 region for årene 2000-2020. Avrund til 2 desimaler.

Sjekker `summary gdp_per_capita`.

```
eu_data |>
  select(gdp_per_capita) |>
  summary()
```

```
gdp_per_capita
Min.   : 3351
1st Qu.: 18455
Median : 23505
Mean   : 25676
3rd Qu.: 29868
Max.   :177745
NA's   :116
```

Vi ser at spennet er svært stort og at vi har 116 NAs.

## Oppgave

14. Bruk `case_when()` for å legge til variabelen `country_name` før vi går videre. Østerrike for AT, Belgia for BE etc..

## Oppgave

15. Lag de tre variablene NUTS2, NUTS1 og NUTSc fra NUTS3. Dette gjøres enkeltst vha. `mutate()` og `str_sub()`. Bruker også `select()` for å få variablene i rekkefølgen: `country_name`, `country`, `year`, `NUTS3`, `NUTS2`, `NUTS1`, `NUTSc`, `gdp`, `pop`, `gdp_per_capita`. NUTSc er vår egen «oppfinnelse» og angir land (to første karakterer i NUTS kode).

## Beregning av Gini på NUTS2, NUTS1 og NUTSc nivå

Vi skal nå beregne Gini for hvert år på NUTS2, NUTS1 og NUTSc nivå. Vi vil beregne Gini utfra `gdp_per_capita` og `pop` i NUTS3 for alle aggregeringsnivåene. Alternativet hadde vært f.eks å bruke `gdp_per_capita` og `pop` på NUTS2 nivå for å regne ut Gini-koeffisient for NUTS1.

Gini-koeffisient er tradisjonelt et mål på *inntektsforskjeller*. Her benytter vi målet for å undersøke hvor jevnt *verdiskapningen* er fordelt mellom regioner. En Gini-koeffisient nær null vil altså her bety at verdiskapningen er jevnt fordelt mellom regionene i et land. En Gini-koeffisient nær 1 vil det derimot bety at det meste av verdiskapningen i et land er sentralisert til en spesifikk NUTS3 region.

Vi starter med NUTS2. Vi benytter funksjonen `Gini()` fra pakken `DescTools` for å beregne Gini-koeffisienter. Bruk populasjon som vektor. Funksjonen har et argument `na.rm` som det er viktig at vi husker å sette til `TRUE`. Regioner med NA verdi for `gdp_per_capita` vil da bli utelatt fra beregningen av Gini. Ellers vil vi etter vanlige R-regler få at Gini-koeffisienten er NA for disse.

### Gini-koeffisient for NUTS2

Vi vil ha med `pop` og `gdp` som variabler. Disse vil være summen av de tilsvarende på NUTS3 nivå (det vi har i `eu_data`).

### Oppgave

16. Bruk koden nedenfor til å beregne Gini-koeffisienter på NUTS2 nivå. Beregn også populasjonen og `gdp` på NUTS2 nivå. Bruk de to siste for å regne ut `gdp_per_capita` for hvert NUTS2 område. Finn også antall NUTS3 regioner som finnes i hver NUTS2 region. Gi denne variabelen navnet `num_nuts3`. Det er viktig at dere beregner Gini-koeffisient før dere aggregerer populasjon og GDP. Resultatet legger dere i en tibble kalt `gini_NUTS2`.

```
gini_NUTS2 <- eu_data |>
  group_by(NUTS2, country_name, country, year) |>
  summarise(
    gini_nuts2 = Gini(
      x = gdp_per_capita,
      weights = pop,
      na.rm = TRUE
    ),
    pop = sum(pop, na.rm = TRUE),
    gdp = sum(gdp, na.rm = TRUE),
    gdp_per_capita = gdp / pop,
    num_nuts3 = n(),
```

```

    .groups = "drop"
  ) |>
  select(country_name, country, NUTS2, year, pop, gdp,
         gdp_per_capita, num_nuts3, gini_nuts2)

```

```

gini_NUTS2 |>
  summary() |>
  print(width = 80)

```

| country_name     | country          | NUTS2            | year             |
|------------------|------------------|------------------|------------------|
| Length:4555      | Length:4555      | Length:4555      | Length:4555      |
| Class :character | Class :character | Class :character | Class :character |
| Mode :character  | Mode :character  | Mode :character  | Mode :character  |

| pop              | gdp               | gdp_per_capita | num_nuts3      |
|------------------|-------------------|----------------|----------------|
| Min. : 0         | Min. :8.553e+07   | Min. : 3351    | Min. : 1.000   |
| 1st Qu.: 658430  | 1st Qu.:1.571e+10 | 1st Qu.:19765  | 1st Qu.: 2.000 |
| Median : 1385717 | Median :3.397e+10 | Median :25073  | Median : 4.000 |
| Mean : 1825234   | Mean :5.006e+10   | Mean : Inf     | Mean : 4.919   |
| 3rd Qu.: 2336768 | 3rd Qu.:6.254e+10 | 3rd Qu.:32054  | 3rd Qu.: 6.000 |
| Max. :12317279   | Max. :6.997e+11   | Max. : Inf     | Max. :23.000   |

```

  gini_nuts2
Min. :0.0000
1st Qu.:0.0600
Median :0.1009
Mean :0.1208
3rd Qu.:0.1617
Max. :0.4744
NA's :851

```

Vi ser at vi har et spenn i Gini-koeffisienten på NUTS2 nivå fra 0.00 til 0.4744. Vi har også 815 NAs som stammer fra de 133 NA-ene vi har i `pop`. Vi ser også at antall NUTS3 i NUTS2 regioner spenner fra 1 til 23.

Sjekker obs. med Gini avrundet til 0,0000.

```

gini_NUTS2 |>
  select(-country_name) |>
  filter(gini_nuts2 < 0.001) |>
  as_flextable(show_coltype = FALSE) |>

```



```
delete_part("footer") |>
width(width = 5/8)
```

| country | NUTS2 | year | pop       | gdp            | gdp_per_capita | nuts3 | gini_nuts2 |
|---------|-------|------|-----------|----------------|----------------|-------|------------|
| AT      | AT34  | 2002 | 352,574   | 9,450,050,268  | 26,803.0       | 2     | 0.0        |
| ES      | ES43  | 2001 | 1,059,011 | 12,749,280,203 | 12,038.9       | 2     | 0.0        |
| ES      | ES43  | 2006 | 1,074,937 | 17,609,870,608 | 16,382.2       | 2     | 0.0        |
| IT      | ITF5  | 2006 | 590,111   | 11,135,870,180 | 18,870.8       | 2     | 0.0        |
| NO      | NO09  | 2018 | 719,531   | 22,567,130,036 | 31,363.7       | 2     | 0.0        |
| NO      | NO09  | 2019 | 722,955   | 22,561,790,200 | 31,200.7       | 2     | 0.0        |
| PL      | PL43  | 2011 | 1,010,700 | 14,231,160,408 | 14,080.5       | 2     | 0.0        |

Vi ser at NUTS2 regioner med svært lave Gini-koeffisient består av bare to NUTS3 regioner. Generelt kan Gini-koeffisient fort bli misvisende nå vi har få observasjoner i en gruppe.

## Oppgave

17. Beregn Gini-koeffisienter på NUTS1 nivå. Legg resultatet i `gini_NUTS1`.

```
gini_NUTS1 |>
summary() |>
print(width = 76)
```

|                  |                  |                  |
|------------------|------------------|------------------|
| country_name     | country          | NUTS1            |
| Length:1727      | Length:1727      | Length:1727      |
| Class :character | Class :character | Class :character |
| Mode :character  | Mode :character  | Mode :character  |

|                  |                  |                   |                |
|------------------|------------------|-------------------|----------------|
| year             | pop              | gdp               | gdp_per_capita |
| Length:1727      | Min. : 0         | Min. :5.875e+08   | Min. : 6423    |
| Class :character | 1st Qu.: 2173477 | 1st Qu.:4.866e+10 | 1st Qu.:20366  |
| Mode :character  | Median : 3889914 | Median :9.611e+10 | Median :25912  |
|                  | Mean : 4814093   | Mean :1.320e+11   | Mean : Inf     |
|                  | 3rd Qu.: 6061422 | 3rd Qu.:1.623e+11 | 3rd Qu.:33120  |
|                  | Max. :18064692   | Max. :6.997e+11   | Max. : Inf     |

| num_nuts3     | gini_nuts1      |
|---------------|-----------------|
| Min. : 1.00   | Min. :0.01583   |
| 1st Qu.: 6.00 | 1st Qu.:0.08447 |
| Median : 9.00 | Median :0.12643 |
| Mean :12.97   | Mean :0.13508   |
| 3rd Qu.:16.00 | 3rd Qu.:0.16738 |
| Max. :96.00   | Max. :0.41632   |
|               | NA's :253       |

Ser at vi har et spenn i Gini-koeffisienten på NUTS1 nivå fra 0.0158 til 0.4163. Antall NAs er nå 253. Vi ser at antall NUTS3 i NUTS1 regioner spenner helt fra 1 til 96.

## Oppgave

18. Beregn Gini-koeffisienter (ut fra variasjon i verdiskapning på NUTS3 nivå) på nasjonsnivå. Legg resultatet i `gini_NUTSc`.

```
gini_NUTSc |>
  summary() |>
  print(width = 80)
```

| country_name     | country          | NUTSc            | year             |
|------------------|------------------|------------------|------------------|
| Length:333       | Length:333       | Length:333       | Length:333       |
| Class :character | Class :character | Class :character | Class :character |
| Mode :character  | Mode :character  | Mode :character  | Mode :character  |

| pop              | gdp               | gdp_per_capita | num_nuts3      |
|------------------|-------------------|----------------|----------------|
| Min. : 3525494   | Min. :9.547e+10   | Min. : 8859    | Min. : 6.00    |
| 1st Qu.: 7870134 | 1st Qu.:2.141e+11 | 1st Qu.:23816  | 1st Qu.: 21.00 |
| Median :10678632 | Median :3.283e+11 | Median :28782  | Median : 41.00 |
| Mean :24966785   | Mean :6.848e+11   | Mean :29818    | Mean : 67.29   |
| 3rd Qu.:42547451 | 3rd Qu.:9.632e+11 | 3rd Qu.:34727  | 3rd Qu.: 73.00 |
| Max. :83166711   | Max. :3.250e+12   | Max. :71486    | Max. :401.00   |

| gini_nutsc     |
|----------------|
| Min. :0.1129   |
| 1st Qu.:0.1434 |
| Median :0.1691 |
| Mean :0.1802   |
| 3rd Qu.:0.2040 |
| Max. :0.4163   |

## «Nestete» datastrukturer

Vi vil nå «neste» de ulike gini\_NUTS\* datasettene og sette dem sammen til et nestet datasett `eu_data_nestet` som inneholder alle dataene ovenfor i en fint ordnet struktur.

### Oppgave

19. Bruk koden nedenfor til å «neste» dataene på NUTS2 nivå.

```
gini_NUTS2_nest <- gini_NUTS2 |>
  group_by(country_name, country) |>
  nest(.key = "NUTS2_data") |>
  ungroup()
```

### Oppgave

20. «Nest» dataene på NUTS1 nivå. Legg resultatet `gini_NUTS1_nest`.

### Oppgave

21. «Nest» dataene på nasjonsnivå. Legg resultatet i `gini_NUTSc_nest`.

### Oppgave


22. Nest dataene på NUTS3 nivå (legg resultatet i en list-column kalt `NUTS3_data`) og bruk `left_join()` til å legge til datasettene `gini_NUTS2_nest`, `gini_NUTS1_nest` og `gini_NUTSc_nest`. Det kan være lurt å benytte en `ungroup()` etter at en har «nestet» `NUTS3_data` for å fjerne gruppestrukturen som vi ikke har bruk for videre.

Når en er sikker på at alt er på plass kan en benytte følgende for å slette alle objekter utenom `eu_data` og `eu_data_nested`.

```
# don't run if you don't mean it.
rm(list = setdiff(ls(), c("eu_data", "eu_data_nested")))
```

## Resultatet

Da skal vi ha et datasett `eu_data_nested` som ser slik ut.



|    | country_name | country | NUTS3_data             | NUTS2_data            | NUTS1_data            | NUTSc_data           |
|----|--------------|---------|------------------------|-----------------------|-----------------------|----------------------|
| 1  | Østerrike    | AT      | <data.frame[770 x 8]>  | <data.frame[198 x 7]> | <data.frame[66 x 7]>  | <data.frame[22 x 7]> |
| 2  | Belgia       | BE      | <data.frame[836 x 8]>  | <data.frame[209 x 7]> | <data.frame[57 x 7]>  | <data.frame[19 x 7]> |
| 3  | Sveits       | CH      | <data.frame[364 x 8]>  | <data.frame[98 x 7]>  | <data.frame[14 x 7]>  | <data.frame[14 x 7]> |
| 4  | Tyskland     | DE      | <data.frame[8822 x 8]> | <data.frame[836 x 7]> | <data.frame[352 x 7]> | <data.frame[22 x 7]> |
| 5  | Danmark      | DK      | <data.frame[264 x 8]>  | <data.frame[132 x 7]> | <data.frame[44 x 7]>  | <data.frame[22 x 7]> |
| 6  | Hellas       | EL      | <data.frame[1144 x 8]> | <data.frame[286 x 7]> | <data.frame[88 x 7]>  | <data.frame[22 x 7]> |
| 7  | Spania       | ES      | <data.frame[1320 x 8]> | <data.frame[440 x 7]> | <data.frame[176 x 7]> | <data.frame[22 x 7]> |
| 8  | Finland      | FI      | <data.frame[418 x 8]>  | <data.frame[110 x 7]> | <data.frame[44 x 7]>  | <data.frame[22 x 7]> |
| 9  | Frankrike    | FR      | <data.frame[2222 x 8]> | <data.frame[594 x 7]> | <data.frame[308 x 7]> | <data.frame[22 x 7]> |
| 10 | Irland       | IE      | <data.frame[169 x 8]>  | <data.frame[66 x 7]>  | <data.frame[22 x 7]>  | <data.frame[22 x 7]> |
| 11 | Italia       | IT      | <data.frame[2376 x 8]> | <data.frame[484 x 7]> | <data.frame[132 x 7]> | <data.frame[22 x 7]> |
| 12 | Nederland    | NL      | <data.frame[902 x 8]>  | <data.frame[286 x 7]> | <data.frame[110 x 7]> | <data.frame[22 x 7]> |
| 13 | Norge        | NO      | <data.frame[182 x 8]>  | <data.frame[112 x 7]> | <data.frame[28 x 7]>  | <data.frame[14 x 7]> |
| 14 | Polen        | PL      | <data.frame[1606 x 8]> | <data.frame[374 x 7]> | <data.frame[154 x 7]> | <data.frame[22 x 7]> |
| 15 | Portugal     | PT      | <data.frame[550 x 8]>  | <data.frame[154 x 7]> | <data.frame[66 x 7]>  | <data.frame[22 x 7]> |
| 16 | Sverige      | SE      | <data.frame[462 x 8]>  | <data.frame[176 x 7]> | <data.frame[66 x 7]>  | <data.frame[22 x 7]> |

Figur 2: Nested versjon av `eu_data`.

Klikker vi f.eks på det firkattede ikonet for Tyskland i `NUTSc_data` kolonnen får vi opp følgende:

|    | year | NUTS3 | NUTS2 | NUTS1 | NUTSc | gdp         | pop    | gdp_per_capita |
|----|------|-------|-------|-------|-------|-------------|--------|----------------|
| 1  | 2000 | DE111 | DE11  | DE1   | DE    | 31064360000 | 582443 | 53334.59       |
| 2  | 2001 | DE111 | DE11  | DE1   | DE    | 34189060000 | 583874 | 58555.54       |
| 3  | 2002 | DE111 | DE11  | DE1   | DE    | 35649930000 | 587152 | 60716.70       |
| 4  | 2003 | DE111 | DE11  | DE1   | DE    | 37674120000 | 588477 | 64019.70       |
| 5  | 2004 | DE111 | DE11  | DE1   | DE    | 37979150000 | 589161 | 64463.11       |
| 6  | 2005 | DE111 | DE11  | DE1   | DE    | 37178730000 | 590657 | 62944.70       |
| 7  | 2006 | DE111 | DE11  | DE1   | DE    | 40012040000 | 592569 | 67523.01       |
| 8  | 2007 | DE111 | DE11  | DE1   | DE    | 41991040000 | 593923 | 70701.15       |
| 9  | 2008 | DE111 | DE11  | DE1   | DE    | 39798530000 | 597176 | 66644.56       |
| 10 | 2009 | DE111 | DE11  | DE1   | DE    | 35685580000 | 600068 | 59469.23       |
| 11 | 2010 | DE111 | DE11  | DE1   | DE    | 40043760000 | 601646 | 66557.01       |
| 12 | 2011 | DE111 | DE11  | DE1   | DE    | 42468740000 | 583868 | 72736.89       |
| 13 | 2012 | DE111 | DE11  | DE1   | DE    | 43686300000 | 591015 | 73917.41       |
| 14 | 2013 | DE111 | DE11  | DE1   | DE    | 43790770000 | 597939 | 73236.18       |
| 15 | 2014 | DE111 | DE11  | DE1   | DE    | 45257400000 | 604297 | 74892.64       |
| 16 | 2015 | DE111 | DE11  | DE1   | DE    | 48464110000 | 612441 | 79132.70       |
| 17 | 2016 | DE111 | DE11  | DE1   | DE    | 48356910000 | 623738 | 77527.60       |
| 18 | 2017 | DE111 | DE11  | DE1   | DE    | 50625360000 | 628032 | 80609.52       |
| 19 | 2018 | DE111 | DE11  | DE1   | DE    | 53666930000 | 632743 | 84816.32       |
| 20 | 2019 | DE111 | DE11  | DE1   | DE    | 50695320000 | 634830 | 79856.53       |

Figur 3: Gini-koeffisient (beregnet fra NUTS3 regioner) for Tyskland. Inneholder også årlige tall for gnp, pop og gnp\_per\_capita.

Går vi inn i NUTS2 kolonnen for Portugal får vi opp følgende:

|    | NUTS2 | year | pop     | gdp         | gdp_per_capita | num_nuts3 | gini_nuts2 |
|----|-------|------|---------|-------------|----------------|-----------|------------|
| 1  | PT11  | 2000 | 3652110 | 46136870000 | 12632.94       | 8         | 0.16443042 |
| 2  | PT11  | 2001 | 3679741 | 48354480000 | 13140.73       | 8         | 0.16025166 |
| 3  | PT11  | 2002 | 3696333 | 49590860000 | 13416.23       | 8         | 0.15413846 |
| 4  | PT11  | 2003 | 3708294 | 50140630000 | 13521.21       | 8         | 0.15099793 |
| 5  | PT11  | 2004 | 3713740 | 50947330000 | 13718.60       | 8         | 0.14939377 |
| 6  | PT11  | 2005 | 3716870 | 54412440000 | 14639.32       | 8         | 0.14621344 |
| 7  | PT11  | 2006 | 3718061 | 57425050000 | 15444.89       | 8         | 0.13910704 |
| 8  | PT11  | 2007 | 3719898 | 60067000000 | 16147.49       | 8         | 0.14126023 |
| 9  | PT11  | 2008 | 3719773 | 61608140000 | 16562.34       | 8         | 0.13613759 |
| 10 | PT11  | 2009 | 3712554 | 59173540000 | 15938.77       | 8         | 0.12188431 |
| 11 | PT11  | 2010 | 3705980 | 61557660000 | 16610.36       | 8         | 0.11712390 |
| 12 | PT11  | 2011 | 3693585 | 59589590000 | 16133.27       | 8         | 0.11405757 |
| 13 | PT11  | 2012 | 3683871 | 58963440000 | 16005.84       | 8         | 0.10731729 |
| 14 | PT11  | 2013 | 3662884 | 61079740000 | 16675.31       | 8         | 0.09831313 |
| 15 | PT11  | 2014 | 3640801 | 62865430000 | 17266.92       | 8         | 0.09877345 |
| 16 | PT11  | 2015 | 3618807 | 64852280000 | 17920.90       | 8         | 0.10043149 |
| 17 | PT11  | 2016 | 3605791 | 66948560000 | 18566.96       | 8         | 0.09824894 |
| 18 | PT11  | 2017 | 3596590 | 68781660000 | 19124.13       | 8         | 0.10567598 |
| 19 | PT11  | 2018 | 3592401 | 72303120000 | 20126.68       | 8         | 0.10202536 |
| 20 | PT11  | 2019 | 3591630 | 75011090000 | 20884.97       | 8         | 0.10173124 |

Figur 4: NUTS2 soner for Portugal årene 2000-2020.


## Plots som viser utviklingen

### Oppgave

23. Lag et lineplot i ggplot som viser utviklingen i Gini-koeffisient på nasjonsnivå for de 16 landene vi har med. Husk argumentet `group =`. Resultatet skal bli som vist i Figur 5.

Sortert tabell for Gini i år 2021 som gjør det litt lettere å se hvilken linje som hører til hvilket land.

```
eu_data_nested |>
  unnest(NUTSc_data) |>
  filter(year == 2021) |>
  select(country_name, gini_nutsc) |>
  arrange(desc(gini_nutsc)) |>
  flextable() |>
  width(1, width = 1.5) |>
  width(2, width = 1.5)
```



Figur 5: Utviklingen over tid for Gini-koeffisienten for de 16 landene. Husk at Gini-koeffisienten her måler endring i hvordan verdiskapningen i landet er fordelt mellom NUTS3 regioner.

Tabell 5: Gini-koeffisient for gnp i 2021. Sveits er ikke i tabellen pga. manglende data.

| country_name | gini_nutsc |
|--------------|------------|
| Irland       | 0.3965377  |
| Polen        | 0.2290067  |
| Frankrike    | 0.2133818  |
| Hellas       | 0.2048054  |
| Tyskland     | 0.2045605  |
| Belgia       | 0.1934180  |
| Italia       | 0.1855265  |
| Danmark      | 0.1842340  |
| Nederland    | 0.1564799  |
| Sveits       | 0.1465714  |

| country_name | gini_nutsc |
|--------------|------------|
| Norge        | 0.1436867  |
| Spania       | 0.1356330  |
| Sverige      | 0.1312931  |
| Østerrike    | 0.1282549  |
| Portugal     | 0.1228649  |
| Finland      | 0.1174086  |

### Oppgave

24. Hva er det som skjer i Irland? Se nærmere på utvikling i gnp\_per\_capita og Gini-koeffisient for de ulike NUTS2 sonene i Irland.

Tabell 6: GDP per capita i 2021. Sveits er ikke i tabellen pga. manglende data.

| country_name | gdp_per_capita |
|--------------|----------------|
| Irland       | 71,486.36      |
| Norge        | 56,432.67      |
| Sveits       | 51,662.84      |
| Danmark      | 44,192.11      |
| Nederland    | 42,828.61      |
| Sverige      | 40,098.29      |
| Østerrike    | 40,083.72      |
| Belgia       | 39,247.42      |
| Tyskland     | 39,078.76      |
| Finland      | 36,477.09      |
| Frankrike    | 33,953.68      |
| Italia       | 31,420.64      |
| Spania       | 27,516.18      |
| Polen        | 25,979.82      |
| Portugal     | 24,363.37      |
| Hellas       | 20,608.18      |



Ser nærmere på NUTS2 sonene i Irland.

Utvikling i gnp\_per\_capita for NUTS2 sonene i Irland.

Har Irland funnet ut hvordan man lager gull av torv? Nei!

For en forklaring av Irlands spesielle kurver se f.eks [følgende side](#). Kort fortalt var årsaken at Apple Inc. restrukturerte sitt skatteopplegg.

## **Hvordan er verdiskapningen fordelt mellom regionene i ulike land?**

### **Spania**

Spania hadde i år 2020 en Gini-koeffisient lik 0,14 som skulle tilsi en nokså jevn fordeling av økonomisk aktivitet mellom regionene.

### **Oppgave**

25. Lag et line-plot som viser utviklingen i Gini-koeffisientene for NUTS2 regionene i Spania.

### **Oppgave**

26. Gjør tilsvarende for NUTS1 regionene i Spania.

### **Oppgave**


27. Hva kan vi ut fra figurene ovenfor generelt si om fordelingen av den økonomiske aktiviteten mellom regionene i Spania?

### **Oppgave**

28. Lag et line-plot (plottet vist i Figur 6) som viser utviklingen i gdp\_per\_capita (nominelle verdier) for de ulike NUTS2 regionene i Spania. Hva er det vi ser effekten av til høyre i Figur 6?

### **Tyskland**

Tyskland hadde i år 2020 en Gini-koeffisient lik 0,20 som skulle tilsi en nokså jevn fordeling av økonomisk aktivitet mellom regionene. Tyskland ligger likevel relativt høyt blandt landene vi har i vårt utvalg. Dette skulle indikere større spredning mellom regionene i Tyskland.



Figur 6: Utviklingen i gnp\_per\_capita for NUTS2 regioner i Spania. Husk at vi har nominelle verdier så naturlig med en generell økning.

### Oppgave

29. Lag et line-plot som viser utviklingen i Gini-koeffisient for NUTS2 regionene i Tyskland.

Ser at Gini-koeffisientene spenner fra ca. 0.03 til over 0.45. Det ser altså ut til å være store forskjeller mellom NUTS2 regionene i Tyskland. Noen NUTS2 soner ser ut til å være relativt ensartet mhp. verdiskapning, mens andre er preget av store forskjeller mellom NUTS3 regionene.

### Oppgave

30. Sjekk om det samme er tilfelle når vi ser på de større regioner (NUTS1)

### Frankrike

Frankrike hadde i år 2021 en Gini-koeffisient lik 0,213 som også skulle tilsi en nokså jevn fordeling av økonomisk aktivitet mellom regionene. Frankrike ligger imidlertid høyt blant landene vi har i vårt utvalg.

## Oppgave

31. Vis utviklingen i Gini-koeffisient for NUTS2 regionene i Frankrike i et line-plot.

Tabell 7 viser Gini-koeffisientene for franske NUTS2 regioner i 2021.

```
eu_data_nested |>
  unnest(NUTS2_data) |>
  filter(country_name == "Frankrike") |>
  filter(year == 2021) |>
  select(NUTS2, gini_nuts2) |>
  arrange(desc(gini_nuts2)) |>
  flextable() |>
  width(1, width = 1.5) |>
  width(2, width = 1.5)
```

Tabell 7: Gini-koeffisient for NUTS2 regioner i Frankrike 2021.

| NUTS2 | gini_nuts2 |
|-------|------------|
| FR10  | 0.33816116 |
| FRJ2  | 0.17136415 |
| FRK2  | 0.16687855 |
| FRL0  | 0.16444446 |
| FRD2  | 0.14161177 |
| FRM0  | 0.13415073 |
| FRE1  | 0.13405337 |
| FRF2  | 0.12161942 |
| FRK1  | 0.11541173 |
| FRI1  | 0.11478442 |
| FRC1  | 0.10597352 |
| FRI2  | 0.09248565 |
| FRF1  | 0.08982611 |
| FRJ1  | 0.08849470 |
| FRG0  | 0.08487734 |
| FRH0  | 0.07886227 |
| FRC2  | 0.06676309 |

| NUTS2 | gini_nuts2 |
|-------|------------|
| FRB0  | 0.06293257 |
| FRE2  | 0.05495016 |
| FRI3  | 0.05234576 |
| FRD1  | 0.05017448 |
| FRF3  | 0.03622292 |
| FRY1  |            |
| FRY2  |            |
| FRY3  |            |
| FRY4  |            |
| FRY5  |            |

### Oppgave

32. Vis utviklingen i Gini-koeffisient for NUTS1 regionene i Frankrike i et line-plot.

### Oppgave

33. Vi ser at for Frankrike er det en region (FR1) som har klart større forskjeller mht. verdistigning enn de andre. Sjekk denne regionen nærmere.

### Oppgave

34. Vis utviklingen i `gdp_per_capita` for NUTS3 sonene i FR1.

### Oppgave

35. Hva ser ut til å være årsaken til den høye Gini-koeffisienten for FR1?

### Enkle modeller

Vi har brukt nominelle verdier for GNP. Vil vi undersøke om det er noen sammenheng mellom GDP og Gini-koeffisienten bør vi se på endringen i de to variablene.

Er det slik at høyere verdiskapning (velstand) medfører større utjevning mellom regionene? Vi vil bruke en enkel modell `diff_gini_nuts2 ~ diff_gdp_per_capita`. Finner vi en signifikant positiv koeffisient for `diff_gdp_per_capita` indikerer dette økt utjevning mellom regionene når `gdp_per_capita` (velstandsnivå) øker.

Vi gjør først en «data science» studie, der vi beregner en regresjonsmodellen for hver av de 173 NUTS2 regionene vi har. Fra disse 173 modellene plukker vi så ut koeffisienten for `diff_gdp_per_capita`. Vi lager så et «density plot» for disse og genererer også diverse beskrivende statistikk.

Til slutt bruker vi dataene for å utføre en kanskje mer korrekt analyse der vi utnytter panel-strukturen i dataene og estimerer en «fixed effect» modell.

## «Data Science» modeller

### Oppgave

36. Lag datasett for endringer i `gdp_per_capita` og `gini_nuts2`. Bruk gjerne koden nedenfor,

```
NUTS2_diff <- eu_data_nested |>
  unnest(NUTS2_data) |>
  mutate(
    # Når vi tar diff får vi en obs. mindre. Legger derfor inn en NA først
    # i vektoren
    diff_gdp_per_capita = c(NA, diff(gdp_per_capita)),
    diff_gini_nuts2 = c(NA, diff(gini_nuts2))
  ) |>
  select(country_name, country, NUTS2, year, diff_gdp_per_capita, diff_gini_nuts2) %>%
  # Fjerner obs. der vi har NA
  filter(complete.cases()) |>
  group_by(country_name, country, NUTS2) |>
  nest(.key = "NUTS2_diff")
```

### Oppgave

37. Bruk modellen `diff_gini_nuts2 ~ diff_gdp_per_capita` på hver av de 173 NUTS3 regionene vha. en anonym funksjon som «mappes» på «list-column» `NUTS2_diff`. Legg resultatet i en variabel `modell`.
38. Hent ut koeffisientene fra de 173 modellene og legg resultatet i variabelen `mod_coeff`. Gjør dette ved å «mappe» funksjonen `coeff()` på `list_column` modell. (Hint: Husk at hvis vi ønsker en dataframe så må `_df` varianten av `map()`.)

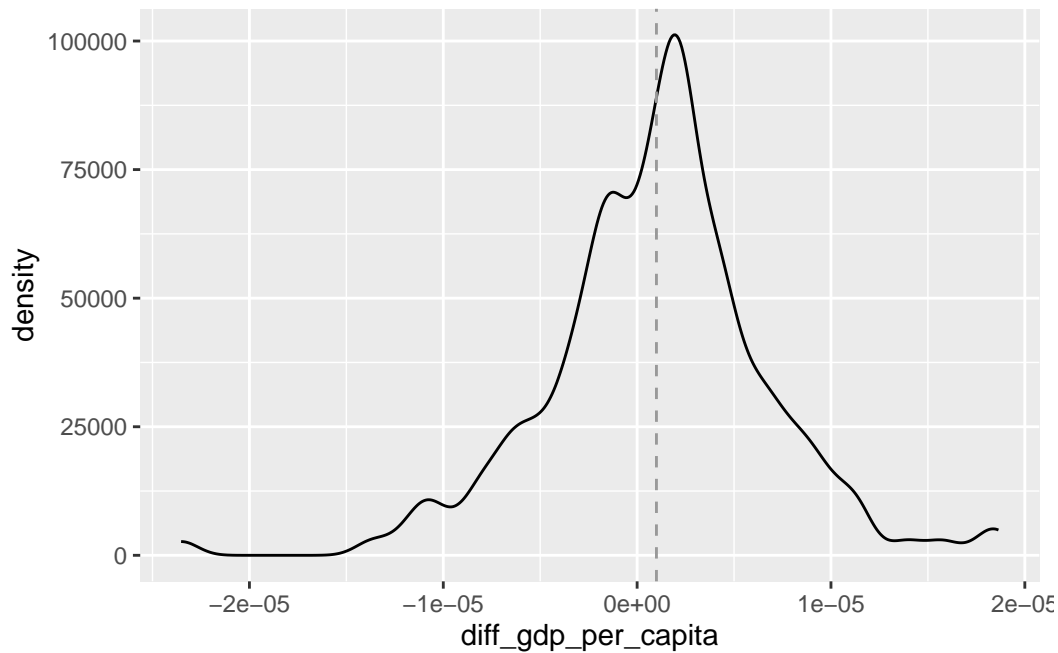
```
NUTS2_diff <- NUTS2_diff |>
  group_by(country_name, country, NUTS2) |>
  mutate(
    mod_coeff = map_df(
      .x = modell,
      .f = coef
    )
  )
```

39. Brukk glance() funksjonen fra broom pakken og «map» denne på modell variabelen for å generere «model summary». Legg resultatet i en variabel mod\_sum.

```
NUTS2_diff <- NUTS2_diff |>
  group_by(country_name, country, NUTS2) |>
  mutate(
    mod_sum = map_df(
      .x = modell,
      .f = glance
    )
  )
```

40. Bruk ggplot til å lage et «density plot» av til variabelen diff\_gdp\_per\_capita. Legg inn en vertikal linje for gjennomsnitt diff\_gdp\_per\_capita. (Hint! Husk argumentet na.rm = TRUE.)

```
NUTS2_diff$mod_coeff |>
  ggplot() +
  geom_density(mapping = aes(x = diff_gdp_per_capita), adjust = 0.6) +
  geom_vline(mapping = aes(xintercept = mean(diff_gdp_per_capita, na.rm = TRUE)),
    colour = "gray60",
    linetype = "dashed")
```



41. Hvor mange av de 173 reggersjonskoeffisientene for `diff_gdp_per_capita` er positive?
42. Finn gjennomsnitt («mean») av de 173 koeffisientene beregnet for `diff_gdp_per_capita`.
43. Utfør en enkel t-test for å teste om `diff_gdp_per_capita` er signifikant større enn 0.

### Panel modell

44. Bruk funksjonen `plm()` fra pakken `plm` til å utføre en panel-regresjon på dataene. For argumentet `index` kan dere bruke `index = c("NUTS2", "year")`. Bruk samme enkle modell som ovenfor dvs. `diff_gini_nuts2 ~ diff_gdp_per_capita`. Putt resultatet av regresjonen i et objekt `p_mod`.
45. Vis `summary()` for `p_mod` og tolk resultatet.
46. En alternativ måte å finne `summary()` for `p_mod` er gjengitt i chunk-en nedenfor. Forklar hva som blir gjort her og sammenlign med resultatet av en ordinær `summary()`.

```
summary(p_mod, vcov = function(x) vcovHC(x, method = "white2"))
```

Oneway (individual) effect Within Model

Note: Coefficient variance-covariance matrix supplied: function(x) vcovHC(x, method = "white2")

Call:

```
plm(formula = "diff_gini_nuts2 ~ diff_gdp_per_capita", data = unnest(select(NUTS2_diff,
```

```

NUTS2, NUTS2_diff), NUTS2_diff), index = c("NUTS2", "year"))

Unbalanced Panel: n = 173, T = 13-22, N = 3677

Residuals:
      Min.      1st Qu.      Median      3rd Qu.      Max.
-0.26115744 -0.00662310 -0.00083892  0.00496514  0.30950518

Coefficients:
              Estimate Std. Error t-value Pr(>|t|)
diff_gdp_per_capita 2.7328e-06 1.3347e-07  20.476 < 2.2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Total Sum of Squares:    2.0302
Residual Sum of Squares: 1.7158
R-Squared:              0.15488
Adj. R-Squared: 0.11314
F-statistic: 419.248 on 1 and 172 DF, p-value: < 2.22e-16

```